

Proyecto Diana

19/02/26

Objetivo

Obtener los bfile de los 660 individuos con las variantes SNPs y SNVs de los genes CYP (CYP1A2, CYP2B6, CYP2C9, CYP2C19, CYP2D6, CYP3A4 y CYP3A5)

Pasos

1. Sacar de los 5374 individuos, los 722 individuos con info de RNA

Se eliminan 62 porque no estan en la tabla de los 5374 (ascendencia no europea u otras razones)

Resultado: 660indv.txt (familia (columna 1), ID individuo (columna 2))

2. Sacar la info necesaria de los CYPs

cromosoma, start y end de UCSC Genome Browser (a start y end se le pone una VENTANA de 5000)

Se hace una para el GRCh37/hg19 para las SNPs y se le llama CYPsconventana19SNP

Se hace una para el GRCh38/hg38 para las SNVs y se le llama CYPsconventana38SNV

id del gen de <https://ensembl.org/>

Resultado: CYPsconventana.txt

3. PLINK para sacar los SNPs de los CYPs de los 660 individuos

Los bfile de input: 5374_indiv_586000_SNP_hg38_020725.hg19.ch.fl.bgn.fam tiene 5374 individuos y 5374_indiv_586000_SNP_hg38_020725.hg19.ch.fl.bgn.bim tiene 9060687 SNPs

```
module load plink/1.90
plink --bfile bfile_og/5374_indiv_586000_SNP_hg38_020725.hg19.ch.fl.bgn --keep
660indv.txt --extract 'range' CYPsconventana19SNP.txt --make-bed --out
660indivCYP_SNP_05_03_26
```

Los bfile de output: 660indivCYP_SNP_19_02_26.fam tiene 660 individuos y 660indivCYP_SNP_19_02_26.bim tiene 943 SNPs

4. PLINK para sacar los SNVs de los CYPs de los 660 individuos

Se adapta el archivo de los 660indv.txt para que siga la estructura coorrecta (ID individuo (columna 1), ID individuo (columna 2)) como 660_indiv_4_SNVs.list

Los bfile de input: 5668_indiv_110742_SNVs_hg38_091224.fam tiene 5668 individuos y 5668_indiv_110742_SNVs_hg38_091224.bim tiene 110742 SNVs

```
plink --bfile bfile_SNVs/5668_indiv_110742_SNVs_hg38_091224 --keep
660_indiv_4_SNVs.list --extract 'range' CYPsconventana38SNV.txt --make-bed --
out 660indivCYPs_SNVs_05_03_26
```

Los bfile de output: 660indivCYPs_SNVs_05_03_26.fam tiene 660 individuos y 660indivCYPs_SNVs_05_03_26.bim tiene 342 SNVs

5. PLINK para fusionar los bfile con SNPs y SNVs

Se adapta el archivo 660indivCYPs_SNVs_19_02_26.fam para que tenga el mismo formato que 660indivCYPs_SNVs_05_03_26.fam (1º y 2º columna con el ID del individuo) y se fusionan los bfile de ambos

```
plink --bfile 660indivCYPs_SNVs_19_02_26 --bmerge
660indivCYPs_SNVs_05_03_26.bed 660indivCYPs_SNVs_05_03_26.bim
660indivCYPs_SNVs_05_03_26.fam --make-bed --out 660indivCYPs_SNVs_05_03_26
```

Los bfile de output: 660indivCYPs_SNVs_05_03_26.fam tiene los 660 individuos y 660indivCYPs_SNVs_05_03_26.bim las 1260 variantes, se repiten 25 variantes

Resultados

Tras filtrar por individuos con info de RNA y familia quedan 660 individuos y tras filtrar por las variantes en los genes CYP quedan 1260 variantes

24/02/26

Objetivo

Leer el artículo de GenoStaR y el Readme de gitbub para comprender como funciona, el input y output

Resultados

Esquema (en el cuaderno) del artículo de GenoStaR y todo preperado para empezar a descargar GenoStaR en R

26/02/26

Objetivo

Formatear los bfile para convertirlos en el input para GenoStaR

Pasos

Descargar GenoStaR en R studio

Esta en el script de R script_genostar

Hacer la prueba con los datos de muestra del github

Esta en el script de R script_genostar

Hacer el archivo input con el formato para genostar

1. Pasar los bfile a ped y map file (son mas sencillos de usar) con plink

```
plink --bfile 660indivCYPs_SNVs_05_03_26 --out  
660indivCYPs_SNVs_05_03_26 --recode
```

Te saca 660indivCYPs_SNVs_05_03_26.map y 660indivCYPs_SNVs_05_03_26.ped

2. Conseguir el map file adaptado juntando el excel el CYP al que pertenece el rs y el rs (CYP_rs)

Con el excel concatenar_CYPs se formatea el map file y se guarda como
map_660indivCYPs_SNVs_05_03_26_formato_geno.txt

3. Meter map, ped y map adaptado al el script de R formatear_input_genostar para generar la matrix_geno_fixed_05_03 (formato de input correcto para genostar)

Aplicar genostar sobre los datos

Esta en el script de R script_genostar, se aplica sobre matrix_geno_fixed_05_03

Resultados

La descarga ha ido bien, la prueba tambien, se ha formateado correctamente el input y se ha dejado corriendo genostar con nuestros datos

03/03/26

Objetivo

Optimizar genostar para nuestros datos

Pasos

Esta todo en el script de R script_genostar, se aplica sobre matrix_geno_fixed

Aplicar genostar sobre los datos

No funciona, se queda pillado durante horas

Aplicar genostar sobre los datos para cada CYP

No funciona, se queda pillado durante horas

Aplicar genostar sobre los datos para cada CYP de solo los primeros 5 individuos

Funciona para CYP1A2 (new), CYP3A4 y CYP3A5. Se decide seguir con estos y ya se vera luego que pasa con los otros

Aplicar genostar sobre el primer individuo para los tres CYPs que funcionan

Sale bien

Resultados

Genostar no saca info para CYP2D6, CYP2B6, CYP2C19 y CYP2C9. Pero si que funciona para CYP1A2 (new), CYP3A4 y CYP3A5 por separado para pocos individuos. Para el primer individuo sale cuando se aplican todos juntos. Asi que se decide hacer un bucle que pase por todos los individuos para estos tres CYPs, para que no aumente el tiempo de CPU y se colapse como ocurría.

05/03/26

Objetivo

Optimizar genostar para nuestros datos

Pasos

Esta todo en el script de R script_genostar, se aplica sobre matrix_geno_fixed

Bucle Aplicar genostar sobre los datos

Se hace y se intenta optimizar el bucle, pero no funciona porque necesita mucha RAM

Repetir lo del día 19/02/26 y 26/02/26 para los SNV sobre GRCh38/hg38

Nos dimos cuenta de que las SNVs estaban hechas para GRCh37/hg19, mientras que los datos que nos habían dado eran de GRCh38/hg38, así que se volvió a hacer todo sobre GRCh38/hg38. (Se deja lo que se hizo corregido sobre esos días)

Resultados

Se vuelve a crear todo pero bien, para el próximo día seguir optimizando GenoStaR y la RAM

10/03/26

Objetivo

Optimizar genostar para nuestros datos

Pasos

Esta todo en el script de R script_genostar, se aplica sobre matrix_geno_fixed

Bucle Aplicar genostar sobre los datos

Se prueban varios bucles, haciendo que no se genere un data frame por cada individuo (para que no ocupe tanto) y que genere un único dataframe con solo el individuo y su diplotipo, pero sigue dando el problema de la RAM

Resultados

La RAM sigue dando problemas aún optimizando lo máximo posible el bucle

12/03/26

Objetivo

Optimizar genostar para nuestros datos

Pasos

Esta todo en el script de R script_genostar, se aplica sobre matrix_geno_fixed

Bucle Aplicar genostar sobre los datos

Se prueban varios bucles, haciendo que no se genere un data frame por cada individuo (para que no ocupe tanto) y que genere un único dataframe con solo el individuo y su diplotipo, pero sigue dando el problema de la RAM

Resultados

La RAM sigue dando problemas aún optimizando lo máximo posible el bucle

17/03/26

Objetivo

Optimizar genostar para nuestros datos

Pasos CYP1A2

Esta todo en el script de R script_genostar, se aplica sobre matrix_geno_fixed

Bucle Aplicar genostar sobre los datos

Se optimiza el bucle para que si se tira más de 5 minutos en una muestra, pase al siguiente y ponga NA para ese individuo

Se corre el bucle para CYP1A2: assign_diplotypes

Genera el objeto R CYP1A2_resultados_final. Hay info de diplotipo para 609 individuos y 51 no tiene diplotipo (NA)

Se sacan los genotipos de esos 51 individuos en df_CYP1A2_NA para poder trabajar con ellos

Imputar los diplotipos de los individuos NA de CYP1A2

Se hace a mano comparando el data frame con los genotipos de esos 51 individuos df_CYP1A2_NA y la tabla de internet CYP1A2_Haplotypes-PS216394-1454147960 que se filtra a CYP1A2_Haplotypes_FILTRADO (esta solo contiene los rs que coincidan para que sea más sencillo imputar)

Pasos CYP3A4

Se corre el bucle de genostar para CYP3A4: assign_diplotypes

Se deja corriendo el bucle de script_genostar para CYP3A4

Resultados

Para CYP1A2 ya se tienen los diplotipos de 609 individuos con genostar y 51 se intenta imputar. Se deja corriendo el bucle para CYP3A4

24/03/26

Objetivo

Terminar de sacar los diplotipos de los 660 individuos para CYP1A2 y CYP3A4

Pasos CYP1A2

Filtrar por los rs que usa genostar

Antes de seguir imputando a mano, se nos ocurre ver si el problema viene de que hay muchos rs en nuestros datos de inicio que Genostar no usa, para ello filtramos de los 51 individuos (df_CYP1A2_NA.csv) solo los rs que aparecen en la tabla de referencia que usa genostar, sacada de github genostar (CYP1A2_Allele_def_2.rda). Todo esta en el script filtrar_rs_referencia_genostar.

Correr el genostar de los NA: assign_diplotype

Se ve que haciendo el filtrado se saca el diplotipo de los 51 pacientes restantes (CYP1A2_resultados_final_NA.rds), por lo que ya tenemos el diplotipo de los 660 pacientes

LIMITACIONES: guardar los rs que usa genostar pero no estan en nuestros datos

Todo esta en el script filtrar_rs_referencia_genostar. Esto se va a poder usar de limitación para ver si hay posibles alelos que no estemos viendo al hacer el filtrado (CYP1A2_Allele_def_rs_excluidos)

Pasos CYP3A4

Tras correr el bucle de script_genostar, se genera el objeto R CYP3A4_resultados_final. Hay info de diplotipo para 620 individuos y 40 no tiene diplotipo (NA)

Se sacan los genotipos de esos 40 individuos en df_CYP3a4_NA para poder trabajar con ellos

Filtrar por los rs que usa genostar

Se filtra de los 40 individuos (df_CYP3A4_NA.csv) solo los rs que aparecen en la tabla de referencia que usa genostar, sacada de github genostar (CYP3A4_Allele_def.rda). Todo esta en el script filtrar_rs_referencia_genostar.

Correr el genostar de los NA: assign_diplotype

Se ve que haciendo el filtrado se saca el diplotipo de los 40 pacientes restantes (CYP3A4_resultados_final_NA.rds), por lo que ya tenemos el diplotipo de los 660 pacientes

LIMITACIONES: guardar los rs que usa genostar pero no estan en nuestros datos

Todo esta en el script filtrar_rs_referencia_genostar. Esto se va a poder usar de limitación para ver si hay posibles alelos que no estemos viendo al hacer el filtrado (CYP3A4_Allele_def_rs_excluidos)

Pasos CYP3A5

Como hemos visto que filtrando para los rs que estan en la referencia de genostar si que funciona y va rapido, para este CYP se va a filtrar antes y luego correr genostar. Se hace todo en filtrar_rs_referencia_genostar

Filtrar por los rs que usa genostar

Se filtra de TODOS los individuos (df_CYP3A5.csv) solo los rs que aparecen en la tabla de referencia que usa genostar, sacada de github genostar (CYP3A5_Allele_def.rda). Todo esta en el script filtrar_rs_referencia_genostar.

LIMITACIONES: guardar los rs que usa genostar pero no estan en nuestros datos

Todo esta en el script filtrar_rs_referencia_genostar. Esto se va a poder usar de limitación para ver si hay posibles alelos que no estemos viendo al hacer el filtrado (CYP3A5_Allele_def_rs_excluidos)

Correr el genostar de TODOS: assign_diplotype

Se saca el diplotipo de los 660 individuos (CYP3A5_resultados_final_diplotipos)

Correr el genostar de TODOS: all_genotype

Da un error al intentar sacar el metabolizador

Resultados

-Para CYP1A2 ya se tienen los diplotipos de 609 individuos en CYP1A2_resultados_final.rds y los 51 individuos restantes en CYP1A2_resultados_final_NA.rds, todos sacados con genostar
-Para el CYP3A4 ya se tienen los diplotipos de 620 individuos en CYP3A4_resultados_final.rds y de los 40 individuos restantes en CYP3A4_resultados_final_NA.rds, todos sacados con genostar.
-Para CYP3A5 ya se tienen los diplotipos de los 660 individuos en CYP3A5_resultados_final_diploipos.rds, pero no los metabolizadores

26/03/26

Objetivo

Reunión con Claudio

Resultados

Me dijo que hasta el momento bien, pero que antes de seguir, me dijo de ir gen por gen y ver porque había rs que nosotros tenemos genotipados pero no usa genostar y ver porque genostar usa rs que no tenemos nosotros. Si es información redundante o si se esta dejando información importante fuera

30/03/26

Objetivo

Analizar rs de CYP1A2 y reunión con Claudio

Resumen rs CYP1A2

Hay 22 rs en comun entre genostar y los nuestros. Nosotros tenemos 60 más que genostar no usa. Genostar usa 24 más que nosotros no tenemos

LIMITACIONES: guardar los rs que usa genostar pero no estan en nuestros datos

Todo esta en el script filtrar_rs_referencia_genostar. Esto se va a poder usar de limitación para ver si hay posibles alelos que no estemos viendo al hacer el filtrado (CYP1A2_Allele_def_rs_excluidos)

Resultados

Me dijo que hasta el momento bien, pero que antes de seguir, me dijo de ir gen por gen y ver porque había rs que nosotros tenemos genotipados pero no usa genostar y ver porque genostar usa rs que no tenemos nosotros. Si es información redundante o si se esta dejando información importante fuera

31/03/26

Objetivo

Hacer tabla CYP1A2_TABLA_COMPLETA

Resumen rs CYP1A2

-Hay 22 rs en comun entre genostar y los nuestros. Nosotros tenemos 60 más que genostar no usa.
Genostar usa 24 más que nosotros no tenemos. En total hay 106 rs

Tabla CYP1A2_TABLA_COMPLETA

Se hace con BUSCARV

-rsID: resultados de R

-POS (hg19): se saca con BUSCARV a hoja SNP (se hace un liftover tambien)

-POS (hg38): se saca con BUSCARV a hoja SNV

-Genostar: con BUSCARV de resultados de R

-Nuestros datos: con BUSCARV de resultados de R

-1K_genomes: se saca con BUSCARV a hoja 1K_genomes (se saca de subset_g1000_chr15.txt al filtrar g1000_noFinnish.bim por cromosoma 15 y las posiciones del CYP1A2 de CYPsconventana19SNP)

```
awk '$1 ~ /^15$/ && $4 > 75036186 && $4 < 75053948 {print}' g1000_noFinnish.bim  
> subset_g1000_chr15.txt
```

-SNP: se saca con BUSCARV a hoja SNP (se saca filtrando por cromosoma 15 el 660indivCYPs_SNP_19_02_26)

-SNV: se saca con BUSCARV a hoja SNV (se saca filtrando por cromosoma 15 el 660indivCYPs_SNV_05_03_26)

-Genotipado: todas las SNVs están imputadas y para las SNPs se sacan con BUSCARV a hoja genotipadas (se saca al filtrar Variantes_genotipas_SNP por cromosoma 15). Undefined para las que no tenemos

-Imputado: al revés que genotipado. Undefined para las que no tenemos

-MAF: se saca con BUSCARV a hoja MAF (del CYP1A2_rs_haploview_data_export, que se saca:)

1. Crear CYP1A2_rs.txt con los 106 rs

2. Sacar ped e info file con plink

Se usan como bfile los g1000_noFinnish (sacado de marte) para solo las rs de CYP1A2_rs.txt

```
plink --bfile g1000_noFinnish --extract CYP1A2_rs.txt --recode HV --out  
CYP1A2_haploview
```

Solo se queda con las 61 rs que están en 1K_genomes porque ha usado g1000_noFinnish

3. Meter en haploview la info

En LINKAGE FORMAT se mete como data file: CYP1A2_haploview.chr-15.ped y como locus info: CYP1A2_haploview.chr-15.info

4. Exportar la tabla de Check Markers como CYP1A2_rs_haploview_data_export

-HWpval: se saca con BUSCARV a hoja MAF

-HOJA LD: se saca del CYP1A2_rs_LD.ld, que se saca:

1. Crear CYP1A2_rs.txt con los 106 rs (ya esta hecho antes)

2. Sacar ped e info file con plink

Se usan como bfile los g1000_noFinnish (sacado de marte) para solo las rs de CYP1A2_rs.txt

```
plink --bfile g1000_noFinnish --extract CYP1A2_rs.txt --r2 --out CYP1A2_rs_LD
```

Solo se queda con las 61 rs que estan en 1K_genomes porque ha usado g1000_noFinnish

3. Meter CYP1A2_rs_LD.ld en la tabla

Resultados

Se termina la tabla CYP1A2_TABLA_COMPLETA

06/04/26

Objetivo

Leer artículo PharmGKB CYP1A2 y analizar tabla CYP1A2_TABLA_COMPLETA

Artículo PharmGKB CYP1A2

"PharmGKB summary: very important pharmacogene information for CYP1A2" del 2012

Se ha visto que esta en nomenclatura old y hay tres rs importantes:

-rs762551: esta en nuestros datos yu en genostar

-rs2069514: esta en nuestros datos pero no en genostar. Se intenta ver si se podría inferir con alguno de los otros rs de genostar: es el rs9 y con haploview se ve que tiene r2 de 73 con los rs50 y rs 51 pero no estan en genostar, al igual que un r2 de 22 con el rs5 que tampoco esta en genostar, por lo que no sepuede inferir

-rs12720461: esta en nuestros datos pero no en genostar. Se hizo lo mismo con el haploview y salian muchos r2 de 22 pero ninguno estaba en genostar

Resumen rs CYP1A2

-Hay 22 rs en comun entre genostar y los nuestros. Nosotros tenemos 60 más que genostar no usa. Genostar usa 24 más que nosotros no tenemos. En total hay 106 rs

-La tabla CYP1A2_TABLA_COMPLETA ya esta hecha

De los 24 rs que estan en genostar pero no en nuestros datos

-Analizando la primera hoja hemos visto que solo hay tres variantes (marcadas en amarillo) que estan en genostar y en 1K_genomes pero no en nuestros datos. Al analizarlas en la hoja LD no salen por lo que no se puede inferir nada de ellas, son singleton

-Analizando el excel CYP1A2_Allele_def_rs_excluidos (sacado con script filtrar_rs_referencia_genostar), se hace una nueva hoja (filtrada) para ver que haplotipos estamos dejando fuera al no tener esos 24 rs en nuestros datos, son 24 haplotipos. Se sacan las frecuencias en la poblacion de estos 24 haplotipos en el excel de CYP1A2_Allele_def_rs_excluidos en la hoja de filtradas, como no hay info en ClinPGX se usa GenomAD y se usa el rs asociado a ese *alelo. Y se ve que todos los *alelos que no se tienen en cuenta tienen un frecuencia muy baja en la poblacion europea (non-Finnish). Hay uno que no se encuentra X3468AC porque tiene nomenclatura rara (marcado en rojo)

De los 60 rs que estan en nuestros datos pero no en genostar

-Hay 8 rs que no estan en 1K_genomes y no se puede hacer nada

-rs2069514 y rs12720461 (del articulo del 2012), resaltados en rojo, estan en nuestros datos pero no en genostar, se intenta ver si se podrian inferir con alguno de los otros rs de genostar con el r2 del haploview, pero con lo que tienen algo de r2 tampoco estan en genostar, asi que son singleton

-En la hoja LD todas las relaciones que salen, los rs estan en nuestros datos pero no en genostar, asi que no se puede hacer nada, son singletons

Resultados

Se terminan las limitaciones del CYP1A2

07/04/26

Objetivo

Hacer y analizar tabla CYP3A4_TABLA_COMPLETA

Resumen rs CYP3A4

-Hay 18 rs en comun entre genostar y los nuestros. Nosotros tenemos 70 más que genostar no usa.

Genostar usa 24 más que nosotros no tenemos. En total hay 112 rs

-Se hace la tabla CYP3A4_TABLA_COMPLETA como para CYP1A2

De los 24 rs que estan en genostar pero no en nuestros datos

-Analizando la primera hoja hemos visto que solo hay dos variantes (marcadas en amarillo) que estan en genostar y en 1K_genomes pero no en nuestros datos. Al analizarlas en la hoja LD no salen por lo que no se puede inferir nada de ellas, son singleton

-Analizando el excel CYP3A4_Allele_def_rs_excluidos (sacado con script filtrar_rs_referencia_genostar), se hace una nueva hoja (filtrada) para ver que haplotipos estamos dejando fuera al no tener esos 24 rs en nuestros datos, son 24 haplotipos. Se sacan las frecuencias en la poblacion de estos 24 haplotipos en el

excel de CYP3A4_Allele_def_rs_excluidos en la hoja de filtradas, como no hay info en ClinPGX se usa GenomAD y se usa el rs asociado a ese *alelo. Y se ve que todos los *alelos que no se tienen en cuenta tienen una frecuencia muy baja en la población europea (non-Finnish), hay algunos que se buscan en el UCSC (marcados en amarillo) y cinco que no se encuentran, cuatro porque tienen nomenclatura rara (marcados en rojo) y uno porque no está su frecuencia en ninguna base de datos (marcado en morado)

De los 60 rs que están en nuestros datos pero no en Genostar

- Hay 15 rs que no están en 1K_genomes y no se puede hacer nada
- En la hoja LD todas las relaciones que salen, los rs están en nuestros datos pero no en Genostar, así que no se puede hacer nada, son singletons

Resultados

Se terminan las limitaciones del CYP3A4

08/04/26

Objetivo

Hacer repositorio Github en el ordenador de aquí y en el mío

Resultados

Se hace el repositorio bien

09/04/26

Objetivo

Mirar las limitaciones de CYP3A5 y sacar diplotipos y limitaciones de CYP2C19, CYP2C9, CYP2B6 y CYP2D6

Resumen rs CYP3A5

- Hay 4 rs en común entre Genostar y los nuestros. Nosotros tenemos 73 más que Genostar no usa. Genostar usa 1 más que nosotros no tenemos. En total hay 78 rs
- Ya no se hace la TABLA COMPLETA para CYP3A5 porque se ha visto que no da info

Del rs que está en Genostar pero no en nuestros datos (limitaciones)

-Analizando el excel CYP3A5_Allele_def_rs_excluidos (sacado con script filtrar_rs_referencia_genostar), se hace una nueva hoja (filtrada) para ver que haplotipos estamos dejando fuera al no tener ese rs en nuestros datos, es 1 haplotipo. Se saca la frecuencia en la población de ese haplotipo en el excel de CYP3A5_Allele_def_rs_excluidos en la hoja de filtradas, se saca de CYP3A5_frequency_table (descargado de ClinPGX pharmacogene table frequencies), se mira ese *alelo para Europeos y se ve que no tiene frecuencia así que bien.

Pasos CYP2B6

En filtrar_rs_referencia_genostar: primero se filtra por rs comunes para que sea más rápido (se guarda CYP2B6_Allele_def_rs_excluidos para las limitaciones) y luego se aplica genostar assign_diplotype (se guarda en CYP2B6_resultados_final_diplotipos). Al usar all_genopheno para metabolizador da error

Resumen rs CYP2B6

-Hay 30 rs en comun entre genostar y los nuestros. Nosotros tenemos 232 más que genostar no usa. Genostar usa 18 más que nosotros no tenemos. En total hay 280 rs
-Ya no se hace la TABLA COMPLETA para CYP2B6 porque se ha visto que no da info

De los 18 que esta en genostar pero no en nuestros datos (limitaciones)

-Analizando el excel CYP2B6_Allele_def_rs_excluidos (sacado con script filtrar_rs_referencia_genostar), se hace una nueva hoja (filtrada) para ver que haplotipos estamos dejando fuera al no tener esos rs en nuestros datos, son 21 haplotipos. Se sacan la frecuencia en la poblacion de esos 21 haplotipos en el excel de CYP2B6_Allele_def_rs_excluidos en la hoja de filtradas, se saca de CYP2B6_frequency_table cinco frecuencias (descargado de ClinPGX pharmacogene table frequencies) las marcadas en verde, se miran esos *alelos para Europeos. Luego hay otras que no tienen info en ClinPGX se usa GenomAD y se usa el rs asociado a ese *alelo, hay cuatro que no se encuentran porque tienen nomenclatura rara (marcados en rojo). El error es muy alto

Diplotipos CYP2B6

En CYP2B6_resultados_final_diplotipos

Pasos CYP2C9

En filtrar_rs_referencia_genostar: primero se filtra por rs comunes para que sea más rápido (se guarda CYP2C9_Allele_def_rs_excluidos para las limitaciones) y luego se aplica genostar assign_diplotype (se guarda en CYP2C9_resultados_final_diplotipos). Al usar all_genopheno para metabolizador da error

Resumen rs CYP2C9

-Hay 41 rs en comun entre genostar y los nuestros. Nosotros tenemos 262 más que genostar no usa. Genostar usa 39 más que nosotros no tenemos. En total hay 342 rs
-Ya no se hace la TABLA COMPLETA para CYP2C9 porque se ha visto que no da info

De los 39 que esta en genostar pero no en nuestros datos (limitaciones)

-Analizando el excel CYP2C9_Allele_def_rs_excluidos (sacado con script filtrar_rs_referencia_genostar), se hace una nueva hoja (filtrada) para ver que haplotipos estamos dejando fuera al no tener esos rs en nuestros datos, son 40 haplotipos. Se sacan la frecuencia en la poblacion de esos 40 haplotipos en el excel de CYP2C9_Allele_def_rs_excluidos en la hoja de filtradas, se saca de CYP2C9_frequency_table ocho frecuencias (descargado de ClinPGX pharmacogene table frequencies) las marcadas en verde, se miran esos *alelos para Europeos. Luego hay otras que no tienen info en ClinPGX se usa GenomAD y se usa el rs asociado a ese *alelo, hay 18 que no se encuentran porque tienen nomenclatura rara (marcados en rojo)

Diplotipos CYP2C9

En CYP2C9_resultados_final_diplo tipos

Pasos CYP2C19

En filtrar_rs_referencia_genostar: primero se filtra por rs comunes para que sea más rápido (se guarda CYP2C19_Allele_def_rs_excluidos para las limitaciones) y luego se aplica genostar assign_diplotype (se guarda en CYP2C19_resultados_final_diplo tipos). Al usar all_geno_pheno para metabolizador da error

Resumen rs CYP2C19

- Hay 24 rs en comun entre genostar y los nuestros. Nosotros tenemos 303 más que genostar no usa. Genostar usa 11 más que nosotros no tenemos. En total hay 338 rs
- Ya no se hace la TABLA COMPLETA para CYP2C19 porque se ha visto que no da info

De los 11 que esta en genostar pero no en nuestros datos (limitaciones)

-Analizando el excel CYP2C19_Allele_def_rs_excluidos (sacado con script filtrar_rs_referencia_genostar), se hace una nueva hoja (filtrada) para ver que haplotipos estamos dejando fuera al no tener esos rs en nuestros datos, son 12 haplotipos. Se sacan la frecuencia en la poblacion de esos 12 haplotipos en el excel de CYP2C19_Allele_def_rs_excluidos en la hoja de filtradas, se saca de CYP2C19_frequency_table dos frecuencias (descargado de ClinPGX pharmacogene table frequencies) las marcadas en verde, se miran esos *alelos para Europeos. Luego hay otras que no tienen info en ClinPGX se usa GenomAD y se usa el rs asociado a ese *alelo, hay cinco que no se encuentran, dos porque tienen nomenclatura rara (marcados en rojo) y tres porque no esta su frecuencia en ninguna base de datos (marcado en morado)

Diplo tipos CYP2C19

No salen todo, salen muchos unknown (CYP2C19_resultados_final_diplo tipos), deberíamos tener en cuenta los CNVs

Pasos CYP2D6

En filtrar_rs_referencia_genostar: primero se filtra por rs comunes para que sea más rápido (se guarda CYP2D6_Allele_def_rs_excluidos para las limitaciones) y luego se aplica genostar assign_diplotype (se guarda en CYP2D6_resultados_final_diplo tipos) pero no sale creo que es por las CNVs

Resumen rs CYP2D6

- Hay 40 rs en comun entre genostar y los nuestros. Nosotros tenemos 77 más que genostar no usa. Genostar usa 110 más que nosotros no tenemos. En total hay 227 rs
- Ya no se hace la TABLA COMPLETA para CYP2B6 porque se ha visto que no da info
- Necesita CNVs
- No se calcula el error, hasta meter las CNVs

Resultados

- Se terminan las limitaciones del CYP3A5 y CYP2B6 bien. El error de CYP2B6 es muy alto mirar la razon
- Tambien se hace el error para CYP2C19 y CYP2C9

- Para CYP2C19 los diplotipos salen mal, deberían mirarse las CNVs
- Para CYP2D6 no sale nada, se necesitan los CNVs

10/04/26

Objetivo

- CNVs
- Organizar carpetas

CNVs en CNV_gene_overlap_database en la hoja filtered (SON PERSONAS)

Hat 125 en total en filtradas

- CYP1A2: nada
- CYP3A4: 1 duplicaçon
- CYP3A5: 1 duplicacion
- CYP2C19: 19 duplicaciones y 2 deleciones
- CYP2C9: 19 duplicaciones
- CYP2B6: 1 duplicacion y 1 delecion
- CYP2D6: 79 duplicaciones y 2 deleciones

Resultados

Hay muchos individuos con CNVs en CYP2D6, CYP2C19 y CYP2C9, hay que mirar si afecta en genostar o no

13/04/26

Objetivo

- Tabla general resumen
- Mirar el error alto de CYP2B6

Tabla general resumen

Se juntan todos los datos de los CYPS en TABLA_RESUMEN_CYPS

- rs total, rs comunes, rs solo nosotros, rs solo genostar: se saca de la info apuntada en este documento
- nº *alelos no tenidos en cuenta en genostar: se saca de CYPX_Allele_def_rs_excluidos. Se añade esta columna porque un rs (de solo genostar) puede dar a más de un alelo
- nº *alelos sin frec poblacional de los *alelos no tenidos en cuenta en genostar: se saca de CYPX_Allele_def_rs_excluidos (marcados en rojo o morado)
- Error rs solo genostar : se saca de CYPX_Allele_def_rs_excluidos

Mirar el error alto de CYP2B6

Un 14.02% del 14.07% del error se debe a la variante rs3211371 que define el *5 y *7 muy frecuentes en la población europea, se cree que es que no esta genotipada. Al buscar en Variantes_genotipas_SNP's no sale y en concatenar_CYPS, que son todas las variantes que tenemos en cuenta. Se me ocurre mirar si esta en LD alto con alguna de las que si que tenemos genotipadas.

MAF y LD y haploview

Se hace la tabla CYP2B6_TABLA_ERROR_LD

-rsID: resultados de R

-Genostar: con BUSCARV de resultados de R

-Nuestros datos: con BUSCARV de resultados de R

-1K_genomes: se saca con BUSCARV a hoja 1K_genomes (se saca de subset_g1000_chr19.txt al filtrar g1000_noFinnish.bim por cromosoma 19 y las posiciones del CYP2B6 de CYPsconventana19SNP)

```
awk '$1 ~ /^19$/ && $4 > 41492187 && $4 < 41529303 {print}' g1000_noFinnish.bim  
> subset_g1000_chr19.txt
```

Nos salen 211 rs que estan tanto en nuestros datos como en 1K_genomes

-MAF: se saca con BUSCARV a hoja MAF (del CYP2B6_rs_haploview_data_export, que se saca:)

1. Crear CYP2B6_rs.txt con los 262 rs que nosotros tenemos y el rs3211371

2. Sacar ped e info file con plink

Se usan como bfile los g1000_noFinnish (sacado de marte) para solo las rs de CYP2B6_rs.txt

```
plink --bfile g1000_noFinnish --extract CYP2B6_rs.txt --recode HV --out  
CYP2B6_haploview
```

Solo se queda con 212 rs, las 211 rs que estan en 1K_genomes porque ha usado g1000_noFinnish y la rs3211371

3. Meter en haploview la info

En LINKAGE FORMAT se mete como data file: CYP2B6_haploview.chr-15.ped y como locus info: CYP2B6_haploview.chr-15.info

4. Exportar la tabla de Check Markers como CYP2B6_rs_haploview_data_export

-HWpval: se saca con BUSCARV a hoja MAF

-HOJA LD: se saca del CYP2B6_rs_LD.ld, que se saca:

1. Crear CYP2B6_rs.txt con los 262 rs que nosotros tenemos y el rs3211371

2. Sacar ped e info file con plink

Se usan como bfile los g1000_noFinnish (sacado de marte) para solo las rs de CYP2B6_rs.txt


```
plink --bfile g1000_noFinnish --extract CYP2B6_rs.txt --r2 --out CYP2B6_rs_LD
```

Solo se queda con 212 rs, las 211 rs que estan en 1K_genomes porque ha usado g1000_noFinnish y la rs3211371

3. Meter CYP2B6_rs_LD.ld en la tabla

Al mirar el haploview es la 170 pero no tiene LD alto con ninguna de las nuestras y en la tabla de LD no aparece

Frecuencia población europea *5 y rs3211371

Es la misma frec asi que perfecto

-5*: 0.11547839 (CYP2B6_frequency_table)

-rs3211371: en GnomAD 0.1230 (https://gnomad.broadinstitute.org/variant/19-41016810-C-T?dataset=gnomad_r4), en 1K_genomes (hoja MAF de CYP2B6_TABLA_ERROR_LD) 0.1230, en dbSNP 0.09212 (<https://www.ncbi.nlm.nih.gov/snp/rs3211371>)

Resultados

Se hace la TABLA_RESUMEN_CYPs (falta CYP2D6 pero cuando tengamos las CNVs nuevas) y todos los errores bien excepto para CYP2B6, que la culpable es rs3211371. Info sobre esta variante:

-La usa genostar pero nosotros no la tenemos

-Si que se genotipó pero por filtrado se eliminó

-Es Trialelica

-Da el *5 sola, *7 con otras variantes y *33 y *34 (pero no contribuyen al error)

-El *5 es muy frecuente en poblacion europea pero da METABOLIZADOR NORMAL

-La frecuencia de *5 y de rs3211371 es la misma

Se llega a la conclusion de que aunque la frecuencia es alta, da metabolizador normal por lo que no importa mucho

14/04/26

Objetivo

-Sacar frecuencias diplotipos, allele star para CYP1A2, CYP3A4, CYP3A5, CYP2C19, CYP2C9 y CYP2B6 y metabolizadores para CYP3A5, CYP2C19, CYP2C9 y CYP2B6

Se generan tablas y gráficas

Tabla CYP_tabla_diplotipos: ID Y DIPLOTIPO

Con cualquiera de los scripts, usa de input CYP_resultados_final_diplotipos

Plot CYP_plot_frec_diplotipos: FRECUENCIA ABSOLUTA DIPLOTIPOS

Con script_plot_frec_diplo tipos, usa de input CYP_resultados_final_diplo tipos
Se ven todos los diplo tipos grises

Plot CYP_plot_prop_diplo tipos: PROPORCIONES DIPL OTIPOS

Con script_plot_prop_diplo tipos, usa de input CYP_resultados_final_diplo tipos
Se ven en rojo los diplo tipos NA, en verde el *1/*1 y en azul otros diplo tipos

Plot CYP_plot_prop_star_allele: PROPORCIONES STAR ALLELES

Con script_plot_prop_allele_star, usa de input CYP_resultados_final_diplo tipos
Se ven en rojo los NA, en verde el *1 y en azul otros *alelos

Plot CYP_plot_prop_diplo tipos_metabolizador: PROPORCIONES DIPL OTIPOS coloreados por METABOLIZADOR

Con script_plot_prop_diplo tipos_metabolizadores, usa de input CYP_resultados_final_diplo tipos y las CYP_Diplo type_Phenotype_Table (pharmacogene tables de ClinPGX)
Se colorean los diplo tipos según el metabolizador

Plot CYPs_plot_prop_metabolizador: PROPORCIONES METABOLIZADOR todos los CYPs

Con script_plot_prop_metabolizador_CYPs, usa de input CYP_resultados_final_diplo tipos y las CYP_Diplo type_Phenotype_Table (pharmacogene tables de ClinPGX)

Resultados

Se saca

- CYP_tabla_diplo tipos: ID Y DIPL OTIPO
- CYP_plot_frec_diplo tipos: FRECUENCIA ABSOLUTA DIPL OTIPOS
- CYP_plot_prop_diplo tipos: PROPORCIONES DIPL OTIPOS
- CYP_plot_prop_star_allele: PROPORCIONES STAR ALLELES
- CYP_plot_prop_diplo tipos_metabolizador: PROPORCIONES DIPL OTIPOS coloreados por METABOLIZADOR (no se hace para CYP1A2 y CYP3A4 porque no hay CYP_Diplo type_Phenotype_Table)
- CYPs_plot_prop_metabolizador: PROPORCIONES METABOLIZADOR todos los CYPs

Estaría bien mirar los metabolizadores de CYP1A2 y CYP3A4

15/04/26

Objetivo

- Charla prevención
- Comparar si las proporciones que nos han salido de *allele star se corresponden con las frecuencias poblacionales esperadas

CYP3A5

Se compara CYP3A5_plot_prop_star_allele con CYP3A5_frequency_table y cuadra perfecto

CYP2C9

Se comparan CYP2C9_plot_prop_star_allele con CYP2C9_frequency_table y cuadra perfecto

CYP2B6

Se comparan CYP2B6_plot_prop_star_allele con CYP2B6_frequency_table, cuadra más o menos excepto el *5 que no esta en nuestros datos y es frecuente en la población

CYP1A2

No hay tabla referencia. CYP1A2_Allele_def_2.rda se pasa a CYP1A2_Allele_def_rs_star_allele, que se filtra por los *alelos que hay en CYP1A2_plot_prop_star_allele y se mira la frecuencia de los rs que los definen. Y cuadran bastante bien con las frecuencias poblacionales

CYP3A4

No hay tabla referencia. CYP3A4_Allele_def.rda se pasa a CYP3A4_Allele_def_rs_star_allele, que se filtra por los *alelos que hay en CYP3A4_plot_prop_star_allele y se mira la frecuencia de los rs que los definen. Y cuadran bastante bien con las frecuencias poblacionales

CYP2C19

No se sacaron bien los diplotipos de este CYP, mirar con CNVs

Resultados

Las frecuencias de los allele star que nos han salido se corresponden con lo esperado en la poblacion bastante bien

16/04/26

Objetivo

- CNVs nuevo
- Reunion Claudio
- Mirar los rs raros rojos ver si los tenemos por posicion

CNVs en CNV_gene_overlap_database_nuevo (SON PERSONAS)

Hat 637 en total en filtradas

- CYP1A2: 2 duplicaciones
- CYP3A4: 99 duplicaciones
- CYP3A5: 78 duplicaciones
- CYP2C19: 89 duplicaciones y 2 deleciones
- CYP2C9: 78 duplicaciones
- CYP2B6: 252 duplicacion y 1 deleccion
- CYP2D6: 34 duplicaciones y 2 deleciones

Ver por posicion si tenemos los rs raros

1. Comparar CYP_Allele_def.rda (la que usa genostar) con CYP_allele_definition_table (ClinPGX) y ver la posicion de los X (rojos) de CYP_Allele_def_rs_excluidos
2. Buscar por posición si nosotros tenemos ese rs en 660indivCYPs_SNVs_05_03_26.bim

CYP1A2

Hay 1 rojo en CYP_Allele_def_rs_excluidos, Se compara CYP1A2_Allele_def_2.rda con CYP1A2_Haplotypes-PS216394-1454147960 y se ve que la que estaba en rojo corresponde al rs2505559894, que no esta en nuestros datos, por lo que se mira su frecuencia y se pone en azul. Frecuencias completas

CYP3A5

Se compara CYP3A5_Allele_def.rda con CYP3A5_allele_definition_table y se ve que todo bien, que no hay cosas raras. Frecuencias completas

CYP2C9

Hay varias rojo en CYP2C9_Allele_def_rs_excluidos, Se compara CYP2C9_Allele_def.rda con CYP2C9_allele_definition_table y se ve que varias en rojo corresponden a rs que no estan en nuestros datos, por lo que se mira su frecuencia y se pone en azul, luego hay otra que se saca por posicion pero no la tenemos y tambien se pone en azul, luego hay otras que no tienen rs asociado y se mira por pisicion en nuestros datos y tampoco asi que se quedan en rojo, pero estan en ClinPGX asi que se pone la frecuencia del *alelo. Frecuencias completas

CYP2C19

Hay varias rojo en CYP2C19_Allele_def_rs_excluidos, Se compara CYP2C19_Allele_def.rda con CYP2C19_allele_definition_table y se ve que algunas en morado y rojo estan en ClinPGX asi que se pone la frecuencia del *alelo. Frecuencias completas

CYP2B6

Hay varias rojo en CYP2B6_Allele_def_rs_excluidos, Se compara CYP2B6_Allele_def.rda con CYP2B6_allele_definition_table y se ve que una en rojo corresponde a rs que no estan en nuestros datos, estan en ClinPGX asi que se pone la frecuencia del *alelo. Luego hay otra (X) que no tiene rs asociado y se mira por pisicion en nuestros datos y tampoco asi que se quedan en rojo. Nos queda un rs sin frecuencia (X)

CYP3A4

Hay 4 rojo en CYP_Allele_def_rs_excluidos, Se compara CYP3A4_Allele_def.rda con CYP3A4_allele_definition_table-PS216409-1454596980 y se ve que dos en rojo corresponden a rs que no estan en nuestros datos, por lo que se mira su frecuencia y se pone en azul, luego hay dos que no tienen rs asociado y se mira por pisicion en nuestros datos y tampoco asi que se quedan en rojo. Algunas estan en ClinPGX asi que se pone la frecuencia del *alelo. Nos quedan 3 rs sin frecuencia (X.3, X.2 y rs1318364992)

Resultados

Hay muchos individuos con CNVs en CYP2D6, CYP2C19 y CYP2C9, hay que mirar si afecta en genostar o no

17/04/26

Objetivo

Organizar un poco todo

Resumen CYPs del error

- CYP12: todas las frecuencias de los rs excluidos sacadas
- CYP2C9: todas las frecuencias de los rs excluidos sacadas
- CYP3A5: todas las frecuencias de los rs excluidos sacadas
- CYP3A4: hay tres rs de los excluidos que no se puede sacar su frecuencia
- CYP2B6: hay un rs de los excluidos que no se puede sacar su frecuencia, tiene VARIANTES ESTRUCTURALES (X.2)
- CYP2C19: todas las frecuencias de los rs excluidos sacadas, tiene VARIANTES ESTRUCTURALES (X) y cuidado que el * de ref es el 38 pero genostar lo cambia
- CYP2D6: mirar los CNVs

Resultados

Mirar las variantes estructurales

20/04/26

Objetivo

- Jugar con genostar para que me saque lo máximo posible en una sola función

script_juntar_dfs_CYPs: genera matriz_final_sin_CNVs_CYP2D6

Coge todas las tablas de referencia que usa genostar para cada CYP y matrix_genome_fixed_spaces y saca los rs comunes en nuestros datos y genostar para cada CYP y los junta todos con el formato correcto para genostar

script_prueba_funciones_genostar y script_todo_genostar: saca los diplotipos, haplotipos, metabolizadores y pie charts

21/04/26

Objetivo

- Apuntar dudas genostar
- Leer información Genostar del github (las funciones de man y en R el genotype_conversion y en data el allele_definitions_snapshot_2025-08-13)

Resultados

- Se hace una jerarquía de las funciones y se hace un resumen general de cada una (en el word Funciones_genostar)
- Apuntar dudas en el cuaderno

22/04/26

Objetivo

- Gestionar las CNVs de CYP2D6
- Probar genostar con la matriz

CNVs de CYP2D6

Se hacen a mano con el custom track de UCSC (CYP2D6_CNVs), se hace para CNVX9 (exon 9), CNVInt6 (intron 6) y CNV5UTR (zona 5UTR) y solo nos salen 3 individuos con CNVs de los 660 totales:

- HSP_0041.CEL: duplicacion en CNVX9 (exon 9), CNVInt6 (intron 6) y CNV5UTR (zona 5UTR)
- PNT_0196.CEL: duplicacion en CNVX9 (exon 9), CNVInt6 (intron 6) y CNV5UTR (zona 5UTR)
- UAM_0343.CEL: delecion en CNVX9 (exon 9) y CNVInt6 (intron 6), normal en CNV5UTR (zona 5UTR)

Juntar CYP2D6_CNVs con matriz_final_sin_CNVs_CYP2D6

En el script script_juntar_dfs_CYPs

Resultados

- Se deja la matriz MATRIZ_FINAL_COMPLETA ya hecha con todos los CYPs y la CNVs de CYP2D6 incluida
- Se prueba genostar con la matriz pero salen errores

1. Al correr CYP2D6 entero

```
lista_diplo tipos <- all_geno_pheno(df,
  c("CYP3A5","CYP1A2","CYP3A4","CYP2C9","CYP2B6","CYP2C19","CYP2D6"), phased = FALSE,
  CYP1A2_name = "new")
Error in rs1065852 == "AA" | "A A" : solo son posibles operaciones para variables de tipo numérico,
compleja o lógico
SE PRUEBA A QUITAR ESE RS
```

2. Al correr all_geno_pheno

```
lista_diplo tipos <- all_geno_pheno(df_sin_rs,
  c("CYP3A5","CYP1A2","CYP3A4","CYP2C9","CYP2B6","CYP2C19","CYP2D6"), phased = FALSE,
  CYP1A2_name = "new")
Error del split
SE HACE ASSIGN_DIPLTYPE
```

3. Correr assign_diplotype

```
lista_diplo tipos <- assign_diplotype(df_sin_rs,
  c("CYP3A5","CYP1A2","CYP3A4","CYP2C9","CYP2B6","CYP2C19","CYP2D6"), phased = FALSE,
  CYP1A2_name = "new")
SALE BIEN, PERO PARA CYP2C19 Y CYP2D6 MUCHOS NA
```

23/04/26

Objetivo

- Reunión Claudio
- Sacar cosas con genostar
- Corregir los errores de los CYPs
- Mirar los problemas del día anterior

Sacar cosas con genostar

En script_genostar

Corregir los errores de los CYPs

En CYP_Allele_def_rs_excluidos, las frecuencias que se han sacado por *alelo hay que verificar que no haya mas rs que dan a ese *alelo o que la frecuencia del rs coincide con la frecuencia del *alelo. Se cambian estas tablas y los errores

Mirar los problemas del día anterior

Se ponen las funciones de genostar en funciones_genostar_diana y se cambian

- adjust_diplotype: se cambia rs1065852 == "AA" | "A A" porque esta mal

Resultados

Se actualizan los errores

27/04/26

Objetivo

- Actualizar errores TABLA_RESUMEN y actualizar error CYP2B6
- Error de CYP2D6

Sacar cosas con genostar

En script_genostar se saca todo con all_geno_pheno y se guarda todo el resultado en salida_genostar y el resultado filtrado con solo las columnas que interesan en salida_genostar_filtrado

Error CYP2D6

En CYP2D6_Allele_def_rs_excluidos. Hay rs problematicos anotados en el cuaderno

Resultados

Se hace el error de CYP2D6 y se mete en TABLA_RESUMEN_CYPs

11/05/26

Objetivo

Hacer script de la grafica final de frecuencias (ClinPGX vs nuestros resultados)

Datos poblacionales: Excel frecuencias_poblacionales_metabolizadores_clinpgx.xlsx

Se hace un excel para CYP2C9, CYP2C19, CYP3A5, CYP2B6 y CYP2D6 con las frecuencias poblacionales de clinpgx (se saca de la pharmacogene table CYP_frequency_table.xlsx de la hoja Phenotype Frequency, para las que tienen activity score (CYP2C9 y CYP2D6) se usa CYP_Diplotype_Phenotype_Table para pasar de activity score a metabolizador)

Nuestros datos: Excel salida_genostar_filtrado

Es la salida de script_genostar

Script_grafica_final_metabolizadores

Se le mete

-Las frecuencias de clinpgx (frecuencias_poblacionales_metabolizadores_clinpgx.xlsx)

-Nuestra salida de genostar (salida_genostar_filtrado)

Y te saca el plot resumen de frecuencias de metabolizadores (plot_final_metabolizadores)

Resultados

La mayoría cuadra, hay que revisar que los porcentajes estén bien y ver que pasa con CYP2C19 y CYP2D6

12/05/26

Objetivo

-Revisar plot_final_metabolizadores

-Hacer plot_final_allele_star

Script_grafica_final_star_alleles

Se le mete:

-Las frecuencias de clinpgx para CYP3A5, CYP2B6, CYP2C19, CYP2C9 y CYP2D6 (se saca de la pharmacogene table CYP_frequency_table.xlsx de la hoja Allele Frequency, se hace la columna European100 para expresar la frecuencia en porcentaje), mientras que para CYP1A2 y CYP3A4 no hay frecuencias en clinpgx se usan las frecuencias de los rs de esos allele star que se sacan de CYP1A2_Allele_def_rs_star_allele y CYP3A4_Allele_def_rs_star_allele y se ponen en frecuencias_poblacionales_allele_star_CYP1A2_CYP3A4_clinpgx

-Nuestra salida de genostar (salida_genostar_filtrado)

Y te saca el plot resumen de frecuencias de allele star (plot_final_allele_star)

Resultados

-El plot_final_metabolizadores está bien, solo falta ver porque para CYP2C19 y CYP2D6 hay muchos NA

-Se hace el plot_final_allele_star y está bien

13/05/26

Objetivo

- Hacer plot_final_activity
- Actualizar tabla TABLA_RESUMEN_CYPS

Script_grafica_final_activity

Se le mete

- Las frecuencias de clinpgx para CYP2C9 y CYP2D6 (frecuencias_poblacionales_activity_clinpgx.xlsx: excel para CYP2C9 y CYP2D6 con las frecuencias poblacionales de clinpgx (se saca de la pharmacogene table CYP_frequency_table.xlsx de la hoja Phenotype Frequency))
 - Nuestra salida de genostar (salida_genostar_filtrado)
- Y te saca el plot resumen de frecuencias de activity (plot_final_activity)

Actualizar tabla TABLA_RESUMEN_CYPS con el CALL RATE

Se calcula el call rate (porcentaje de individuos para los que no se consigue sacar diplotipo) de cada CYP con el script_call_rate

Resultados

- Se hace el plot_final_activity_score y esta bien
- Se actualiza TABLA_RESUMEN_CYPS con el call rate de cada CYP

14/05/26

Objetivo

- Analizar funciones en busca de la razon del bajo call rate para CYP2C19 y CYP2D6

Mejora en la funcion filter_no_match

Se le añade para aparte de "No matching star alleles found" tambien funcione si hay NA (reales o "NA") y se sacan los excels con los individuos a los que no se les ha encontrado diplotipo CYP_individuos_NA

Modificar las tablas de individuos NA tras genostar CYP_individuos_NA

- En la hoja salida genostar: se deja tal cual sale (con todas las columnas)
- En la hoja filtrada: se filtra para los rs y columnas de ese CYP

Buscar la razon por la que salen los NA

Se deja en el cuaderno marcado pero en resumen en CYP_individuos_NA

- Blanco: NA a los que le falta al menos un genotipo
- Naranja: NA pero que tienen todos los genotipos

Resultados

- Se hacen mejoras de las fuciones (en el cuaderno en la parte de mejoras de las funciones genostar)
- Para CYP3A4 y CYP2C9 los NA que salen se deben a que les falta algun dato de genotipado par al menos un rs
- Para CYP2B6 la mayoría de los NA es porque no tienen algun dato de genotipado, excepto 2 que no se

sabe de donde viene porque tienen todos los genotipos

-Para CYP2D6 y CYP2C19 pocos son NA por falta de algun genotipo pero la mayoría (433 para CYP2C19 y 311 para CYP2D6) no se sabe de donde viene porque tienen todos los genotipos

18/05/26

Objetivo

- Hacer abstracts para CBM y Reus
- Posiciones epi
- Ver que individuos de epi coinciden con los 660 individuos

Posiciones de los CYPs para epi

CYP, cromosoma, start y end de UCSC Genome Browser (a start y end se le pone una VENTANA de 100.000) en GRCh38/hg38, id del gen de <https://ensembl.org/>

Resultado: CYPsconventana38epi se ponen las GRCh38/hg38 (se saca de la hoja hg38 ventana 100.000 (epi) de CYPstodo)

Individuos comunes Genostar y epi (individuos_EPIC)

En genostar hay 660 individuos y en epi 238. Todos los de epi tienen genostar

Calcular call rate de genostar para los 238 individuos de epi

1. Filtrar salida genostar para los 238 individuos de epi (salida_genostar_filtrado_epi)

Se coge salida_genostar_filtrado y se filtran los 238 individuos con info de epi

2. Calcular call rate de esos individuos (genostar_CALL_RATE_individuos_epi)

Se usa el script script_CALL_RATE sobre el excel salida_genostar_filtrado_epi

Resultados

- Se suben los abstracts a marte
- Se le pasa a Ines las posiciones de los CYPs con ventana de 100000 (CYPsconventana38epi)
- Los 238 individuos de epi se han corrido en genostar
- Call rate de genostar para los 238 individuos de epi (genostar_CALL_RATE_individuos_epi)

19/05/26

Objetivo

-Analizar funciones en busca de la razon del bajo call rate para CYP2C19 y CYP2D6

Mejoras en la funcion find_missing_data_pre

- Se le añade para aparte de " " tambien funcione si hay NA (reales o "NA") o celda vacia ""
- Se modifica para que acepte cualquier nombre como primera columna y no solo patient_index

Resultado: datos_faltantes

CUIDADO: se hace otra función find_missing_data_pre para aplicarla antes y poder sacar los valores faltantes, pero no se aplica en el pipeline de genostar porque da errores

Solución del bajo call rate de CYP2C19

La MATRIZ_FINAL_COMPLETA se pasa a MATRIZ_FINAL_COMPLETA_CYP2C19 que es la que se usa, se modifica el

-CYP2C19_rs17882687: de CC a AA

-CYP2C19_rs113934938: de AA a GG

Se vuelven a correr los scripts para actualizar

Resultados

-Se hacen mejoras de las funciones (en el cuaderno en la parte de mejoras de las funciones genostar)

20/05/26

Objetivo

-Transcriptómica: sacar media y desviación por CYP y ver donde se expresa cada CYP

-Epi: anotar las CpG que han salido según promotor o isla CpG

-Actualizar TFM

Transcriptómica raw: CYP_gene_counts_238_individuos (son gene_counts)

Epi raw: CpGs_por_CYP_ventana100kb_con_betas (beta values)

Actualizar TFM

En la primera página del cuaderno poner lo que se hace para transcriptómica y epi

Transcriptómica: media y desviación

Los datos de transcriptómica raw son:

Con el script_CYP_media_ds se calcula la media y la desviación típica de cada CYP y se guarda en CYP_gene_counts_238_individuos en la hoja CYP_media_ds y sale que CYP2D6 y CYP3A5 tienen algunos counts

Transcriptómica: expresión de los CYPs

Se busca en The Human Protein Atlas en Tissue:RNA los CYPs y se ve que todos se expresan en el hígado y ninguno en sangre

-CYP2C19, CYP3A4, CYP2C9, CYP1A2 y CYP2B6: nada de expresión en blood

-CYP3A5: tiene un poco de expresión en blood vessel <https://www.proteinatlas.org/ENSG00000106258-CYP3A5/tissue>

-CYP2D6: NO tiene expresión en blood <https://www.proteinatlas.org/ENSG00000100197-CYP2D6/tissue>

Epi: anotación de las CpG

Se guarda en CpGs_por_CYP_ventana100kb_con_betas en sus ventanas correspondientes (se hacen las hojas cosas_CYP para resumir lo que se ve en la ventana)
En la hoja resumen CpGs se apunta las CpGs por gen

Resultados

-Transcriptómica: solo tienen expresión en sangre CYP2D6 y CYP3A5, al comprobar en el Atlas se ve que es que los CYPs se expresan en el hígado y no en sangre
-Epi: se deja anotado en CpGs_por_CYP_ventana100kb_con_betas

25/05/26

Objetivo

Sacar los modelos para la relación entre gene counts y metilación

Transcripción y epi: Modelo simple: $M_{\text{values}} \sim \text{gene_counts}$ (para todos los CYPs)

1. Transcriptómica: pasar los nombres de las muestras de gene counts a formato epi

Con el script relacion_nombres y el excel relacion_nombres_muestras_epi_transcriptomica que tiene ambos formatos, se cambia el excel CYP_gene_counts_nombres_transcriptomica_238_individuos a los nombres de las muestras de epi CYP_gene_counts_nombres_epi_238_individuos

2. Epi: calcular los M-values a partir de los B-values para cada CYP

Con el script transformar_Bvalues_a_Mvalues se pasan los Bvalues del excel CpGs_por_CYP_ventana100kb_con_betas a Mvalues (CpGs_por_CYP_ventana100kb_con_Mvalues.xlsx)
Se usa la fórmula $M = \log_2(B/(1-B))$

3. Fusion: Aplicar modelos

Se adapta el script de Ines del pipeline de epigenómica (14_CaseControl_Analysis_Females_Males_limma_blood_prueba_sin_CtrlProbes3y4) a nuestro caso script modelos_epi_transcriptomica

Resultados

-Se sacan cg significativas en algunos genes

27/05/26

Objetivo

Seguir con modelos_epi_transcriptomica
-Ver como poner el nombre para ver que cg es en el modelo
-Correr el modelo simple para los demás CYPs
-Analizar las significativas

- Ver si es necesario el eBayes o si serviría solo el lmer en nuestro caso
- Ir metiendo covariables (ver si se pueden usar los lambda para ver que modelo es el mejor)

Transcripción y epi: Modelo simple: $M\text{values} \sim \text{gene_counts}$ (para todos los CYPs)

Se analizan las cg significativas,

1. Se considera significativas si tienen un P-valor-ajustado (FDR) >0.05 y solo salen tres para CYP3A5
 - Con LogFC positivo: cg02084114 (más expresión = más metilación)
 - Con LogFC negativo: cg12694063 y cg13596235 (más expresión = menos metilación)
2. Se aplica el Bonferroni (P-valor $< 0.05/\text{CpGs}$) y solo salen dos de los tres de antes de CYP3A5
 - Con LogFC positivo: cg02084114 (más expresión = más metilación)
 - Con LogFC negativo: cg12694063 (más expresión = menos metilación)

Transcripción y epi: Modelo 1: $M\text{values} \sim \text{gene_counts} + \text{age} + \text{sex}$ (para CYP2D6, CYP3A5 porque son las que tienen gene counts)

Salen lo mismo que el modelo simple

Transcripción y epi: Modelo 2: $M\text{values} \sim \text{gene_counts} + \text{age} + \text{sex} + \text{smoking}$ (para CYP2D6 y CYP3A5 porque son las que tienen gene counts)

Salen lo mismo que el modelo simple

Transcripción y epi: Modelo 3: $M\text{values} \sim \text{gene_counts} + \text{age} + \text{sex} + \text{smoking} + \text{caso/control}$ (para CYP2D6 y CYP3A5 porque son las que tienen gene counts)

Se analizan las cg significativas,

1. Se considera significativas si tienen un P-valor-ajustado (FDR) >0.05 y solo sale una para CYP3A5
 - Con LogFC negativo: cg12694063 (más expresión = menos metilación)
2. Se aplica el Bonferroni (P-valor $< 0.05/\text{CpGs}$) y sigue saliendo el de antes de CYP3A5
 - Con LogFC negativo: cg12694063 (más expresión = menos metilación)

Transcripción y epi: Modelo 4: $M\text{values} \sim \text{gene_counts} + \text{age} + \text{sex} + \text{smoking} + \text{cell_1} + \text{cell_2} + \text{Ctrl_1} + \text{Ctrl_2} + \text{anc_1} + \text{anc_2}$ (para CYP2D6 y CYP3A5 porque son las que tienen gene counts)

No salen nada para ninguno de los genes

Transcripción y epi: Modelo completo: $M\text{values} \sim \text{gene_counts} + \text{age} + \text{sex} + \text{smoking} + \text{caso/control} + \text{cell_1} + \text{cell_2} + \text{Ctrl_1} + \text{Ctrl_2} + \text{anc_1} + \text{anc_2}$ (para CYP2D6 y CYP3A5 porque son las que tienen gene counts)

No salen nada para ninguno de los genes

Resultados

Todo para CYP3A5 con Bonferroni

-MS: $M\text{values} \sim \text{gene_counts}$: cg02084114, cg12694063

-M1: Mvalues ~ gene_counts + age + sex: cg02084114, cg12694063
 -M2: Mvalues ~ gene_counts + age + sex + smoking: cg02084114, cg12694063
 -M3: Mvalues ~ gene_counts + age + sex + smoking + caso/control: cg12694063
 -M4: Mvalues ~ gene_counts + age + sex + smoking + cell_1 + cell_2 + Ctrl_1 + Ctrl_2 + anc_1 + anc_2: NADA
 -MC: Mvalues ~ gene_counts + age + sex + smoking + caso/control + cell_1 + cell_2 + Ctrl_1 + Ctrl_2 + anc_1 + anc_2: NADA
 De momento nos quedamos con el M2 (Mvalues ~ gene_counts + age + sex + smoking)

28/05/26

Objetivo

-Aplicar sobre CYP3A5 M5, M6 y M7 de Transcripcion y epi
 -Mirar que son las cg significativas de CYP3A5

Resultados

Todo para CYP3A5 con Bonferroni

-M5: Mvalues ~ gene_counts: cg02084114, cg12694063
 -M1: Mvalues ~ gene_counts + age + sex: cg02084114, cg12694063
 -M2: Mvalues ~ gene_counts + age + sex + smoking: cg02084114, cg12694063
 -M3: Mvalues ~ gene_counts + age + sex + smoking + caso/control: cg12694063
 -M4: Mvalues ~ gene_counts + age + sex + smoking + cell_1 + cell_2 + Ctrl_1 + Ctrl_2 + anc_1 + anc_2: NADA
 -M5: Mvalues ~ gene_counts + age + sex + smoking + cell_1 + cell_2: NADA
 -M6: Mvalues ~ gene_counts + age + sex + smoking + Ctrl_1 + Ctrl_2: cg02084114, cg12694063
 -M7: Mvalues ~ gene_counts + age + sex + smoking + anc_1 + anc_2: cg02084114, cg12694063
 -M8: Mvalues ~ gene_counts + age + sex + smoking + Ctrl_1 + Ctrl_2 + anc_1 + anc_2: cg02084114, cg12694063
 -M9: Mvalues ~ gene_counts + age + sex + smoking + Ctrl_1 + Ctrl_2 + anc_1 + anc_2 + caso/control: cg12694063
 -M10: Mvalues ~ gene_counts + age + sex + smoking + Ctrl_1 + Ctrl_2 + anc_1 + anc_2 + cell_1: NADA
 -MC: Mvalues ~ gene_counts + age + sex + smoking + caso/control + cell_1 + cell_2 + Ctrl_1 + Ctrl_2 + anc_1 + anc_2: NADA
 De momento nos quedamos con el M6 (Mvalues ~ gene_counts + age + sex + smoking + Ctrl_1 + Ctrl_2) porque tienen variables biologicas y tecnicas, se quita cell porque nos elimina los cg significativos, caso/control porque no es lo que buscamos con nuestro estudio de los CYPs y ancestriaporque la poblacion es toda europea y no es el objetivo de nuestro estudio y hemos visto que no afecta, asi que nos quedamos con lo minimo neceario para que sea fiable y no haya sobreajuste

29/05/26

Objetivo

-Hacer el modelo de nuevo sobre las gene_counts normalizadas
 -Mirar que son las cg significativas de CYP3A5

Transcripcion y epi: Modelo simple: $Mvalues \sim gene_counts$ (para todos los CYPs)

Solo salen significativas por Bonferroni en

Para CYP3A5

Se considera significativas si tienen un P-valor-ajustado (FDR) >0.05 y Bonferroni (P-valor $< 0.05/CpGs$)

-Con LogFC positivo: cg02084114 (más expresión = más metilación)

-Con LogFC negativo: cg12694063, cg13596235, cg04706801 y cg05008948 (más expresión = menos metilación)

Para CYP3A4

Se considera significativas si tienen un P-valor-ajustado (FDR) >0.05 y Bonferroni (P-valor $< 0.05/CpGs$)

-Con LogFC positivo: cg11449766 (más expresión = más metilación)

-Con LogFC negativo: cg09914773 (más expresión = menos metilación)

Para los demas CYPs no sale nada

Modelos con covariables

Para CYP3A5

-M0: $Mvalues \sim gene_counts$: cg02084114, cg12694063, cg13596235, cg04706801 y cg05008948 (5cg)

-M1: $Mvalues \sim gene_counts + age + sex$: cg02084114, cg12694063, cg13596235, cg04706801 y cg05008948 (5cg)

-M2: $Mvalues \sim gene_counts + age + sex + smoking$: cg02084114, cg12694063, cg13596235 y cg04706801 (4cg)

-M3: $Mvalues \sim gene_counts + age + sex + smoking + caso/control$: cg12694063 y cg13596235 (2cg)

-M4: $Mvalues \sim gene_counts + age + sex + smoking + cell_1 + cell_2 + Ctrl_1 + Ctrl_2 + anc_1 + anc_2$: cg12694063 (1cg)

-M5: $Mvalues \sim gene_counts + age + sex + smoking + cell_1 + cell_2$: cg12694063 (1cg)

-M6: $Mvalues \sim gene_counts + age + sex + smoking + Ctrl_1 + Ctrl_2$: cg02084114, cg12694063, cg13596235 y cg04706801 (4cg)

-M7: $Mvalues \sim gene_counts + age + sex + smoking + anc_1 + anc_2$: cg02084114, cg12694063, cg13596235 y cg04706801 (4cg)

-M8: $Mvalues \sim gene_counts + age + sex + smoking + Ctrl_1 + Ctrl_2 + anc_1 + anc_2$: cg02084114, cg12694063, cg13596235 y cg04706801 (4cg)

-M9: $Mvalues \sim gene_counts + age + sex + smoking + Ctrl_1 + Ctrl_2 + anc_1 + anc_2 + caso/control$: cg12694063 y cg13596235 (2cg)

-M10: $Mvalues \sim gene_counts + age + sex + smoking + caso/control + cell_1 + cell_2 + Ctrl_1 + Ctrl_2 + anc_1 + anc_2$: cg12694063 (1cg)

De momento nos quedamos con el M8: $Mvalues \sim gene_counts + age + sex + smoking + Ctrl_1 + Ctrl_2 + anc_1 + anc_2$ porque tienen variables biologicas y tecnicas, se quita cell porque nos elimina los cg significativos, caso/control porque no es lo que buscamos con nuestro estudio de los CYPs (se mete ancestry aunque hemos visto que no afecta porque son todo europeos), asi que nos quedamos con lo minimo necesario para que sea fiable y no haya sobreajuste

Para CYP3A4

-MS: Mvalues ~ gene_counts: cg11449766 y cg09914773 (2cg)

-M1: Mvalues ~ gene_counts + age + sex: cg11449766 y cg09914773 (2cg)

-M6: Mvalues ~ gene_counts + age + sex + smoking + Ctrl_1 + Ctrl_2: cg11449766 y cg09914773 (2cg)

-MC: Mvalues ~ gene_counts + age + sex + smoking + caso/control + cell_1 + cell_2 + Ctrl_1 + Ctrl_2 + anc_1 + anc_2: cg11449766 y cg09914773 (2cg)

Da igual el modelo que se coja salen siempre esas dos CpGs así que también M8

cg significativas de CYP3A5

Se analizan las cg significativas en CpGs_por_CYP_ventana100kb_con_betas (para ver donde están) y se marcan en amarillo

1. Se considera significativas si tienen un P-valor-ajustado (FDR) >0.05

-cg02084114 (LogFC positivo: más expresión = más metilación): [https://genome.ucsc.edu/cgi-bin/hgTracks?](https://genome.ucsc.edu/cgi-bin/hgTracks?db=hg38&lastVirtModeType=default&lastVirtModeExtraState=&virtModeType=default&virtMode=0&nonVirtPosition=&position=chr7%3A99337507%2D99937506&hgid=4031321989_w4YZAy5JodQVbAyoa1WZezXWYnbx)

db=hg38&lastVirtModeType=default&lastVirtModeExtraState=&virtModeType=default&virtMode=0&nonVirtPosition=&position=chr7%3A99337507%2D99937506&hgid=4031321989_w4YZAy5JodQVbAyoa1WZezXWYnbx

-cg12694063 (LogFC negativo: más expresión = menos metilación): [https://genome.ucsc.edu/cgi-bin/hgTracks?](https://genome.ucsc.edu/cgi-bin/hgTracks?db=hg38&lastVirtModeType=default&lastVirtModeExtraState=&virtModeType=default&virtMode=0&nonVirtPosition=&position=chr7%3A99531818%2D99731817&hgid=4031331559_lbEHtV4kM0g20nywdJV1gauUmiQQ)

db=hg38&lastVirtModeType=default&lastVirtModeExtraState=&virtModeType=default&virtMode=0&nonVirtPosition=&position=chr7%3A99531818%2D99731817&hgid=4031331559_lbEHtV4kM0g20nywdJV1gauUmiQQ

-cg13596235 (LogFC negativo: más expresión = menos metilación): [https://genome.ucsc.edu/cgi-bin/hgTracks?](https://genome.ucsc.edu/cgi-bin/hgTracks?db=hg38&lastVirtModeType=default&lastVirtModeExtraState=&virtModeType=default&virtMode=0&nonVirtPosition=&position=chr7%3A99532028%2D99732027&hgid=4031502761_oK6msl8c1aKahG7mw89lp6Hkia0d)

db=hg38&lastVirtModeType=default&lastVirtModeExtraState=&virtModeType=default&virtMode=0&nonVirtPosition=&position=chr7%3A99532028%2D99732027&hgid=4031502761_oK6msl8c1aKahG7mw89lp6Hkia0d

-cg04706801 (LogFC negativo: más expresión = menos metilación): [https://genome.ucsc.edu/cgi-bin/hgTracks?](https://genome.ucsc.edu/cgi-bin/hgTracks?db=hg38&lastVirtModeType=default&lastVirtModeExtraState=&virtModeType=default&virtMode=0&nonVirtPosition=&position=chr7%3A99524259%2D99724258&hgid=4031935157_CCFgVliD8gFAA4ReVQ4xDHn8wyZo)

db=hg38&lastVirtModeType=default&lastVirtModeExtraState=&virtModeType=default&virtMode=0&nonVirtPosition=&position=chr7%3A99524259%2D99724258&hgid=4031935157_CCFgVliD8gFAA4ReVQ4xDHn8wyZo

-cg05008948 (LogFC negativo: más expresión = menos metilación): [https://genome.ucsc.edu/cgi-bin/hgTracks?](https://genome.ucsc.edu/cgi-bin/hgTracks?db=hg38&lastVirtModeType=default&lastVirtModeExtraState=&virtModeType=default&virtMode=0&nonVirtPosition=&position=chr7%3A99533591%2D99733590&hgid=4031937755_SlqfxAtdPHat5athFcJjbC6sYNGq)

db=hg38&lastVirtModeType=default&lastVirtModeExtraState=&virtModeType=default&virtMode=0&nonVirtPosition=&position=chr7%3A99533591%2D99733590&hgid=4031937755_SlqfxAtdPHat5athFcJjbC6sYNGq (esta se va al aplicar el M8)

cg significativas de CYP3A4

Se analizan las cg significativas en CpGs_por_CYP_ventana100kb_con_betas (para ver donde están) y se marcan en amarillo

-cg11449766 (LogFC positivo: más expresión = más metilación): no sale buscando la cg en UCSC así que se busca su posición (99860727) cae en CYP3A43 [https://genome.ucsc.edu/cgi-bin/hgTracks?](https://genome.ucsc.edu/cgi-bin/hgTracks?db=hg38&lastVirtModeType=default&lastVirtModeExtraState=&virtModeType=default&virtMode=0&nonVirtPosition=&position=chr7%3A99860727%2D99860727&hgid=4031321989_w4YZAy5JodQVbAyoa1WZezXWYnbx)

db=hg38&lastVirtModeType=default&lastVirtModeExtraState=&virtModeType=default&virtMode=0&no
nVirtPosition=&position=chr7%3A99754539%2D99868513&hgsid=4031942255_kRKx7wyuAudr4gAQB4v
W6a1371AY

-cg09914773 (LogFC negativo: más expresión = menos metilación): [https://genome.ucsc.edu/cgi-](https://genome.ucsc.edu/cgi-bin/hgTracks?)
[bin/hgTracks?](https://genome.ucsc.edu/cgi-bin/hgTracks?)

db=hg38&lastVirtModeType=default&lastVirtModeExtraState=&virtModeType=default&virtMode=0&no
nVirtPosition=&position=chr7%3A99752211%2D99789608&hgsid=4031942255_kRKx7wyuAudr4gAQB4v
W6a1371AY

01/06/26

Objetivo

-Transcripcion y metabolizador: Hacer regresion lineal tipo metabolizador con expresion (gene counts) sin
covariables (gene_counts ~ metabolizador (factor) SOLO para los CYPs con info de metabolizador)

Transcripcion y metabolizador: Modelo simple sobre los 238 individuos de epi

1. Transcriptomica: ya estan las gene_counts
(CYP_gene_counts_normalizadas_nombres_transcriptomica_238_individuos)

2. Tipo metabolizador: filtrar y formatear los datos de input

Se parte del excel salida_genostar_filtrado_epi y se filtra para solo tener la info del matbolizer status y de
la misma forma, se guarda en CYP_metabolizador_nombres_genostar_238_individuos

3. Fusion: Aplicar modelos

Con script_modelos_metabolizador_transcriptomica, se hace un modelo lineal sin basarse en limma y no
hay correlación en ninguno de los casos

No sale nada significativo

-CYP2D6: 0.7955

-CYP2B6: 0.1235

-CYP3A5: 0.4165

-CYP2C9: 0.8315

-CYP2C19: 0.9055

Resultados

-Transcripcion y metabolizador: No sale nada significativo para regresion transcriptomica y tipo de
metabolizador para los 238 individuos de epi

02/06/26

Objetivo

-Transcripcion y metabolizador: y Hacer regresion lineal tipo metabolizador con expresion (gene counts)
sin covariables (gene_counts ~ metabolizador (factor) SOLO para los CYPs con info de metabolizador)

para los 660 individuos

-Transcription y epi: Mirar si las CpGs del CYP3A5 son DMR mirando si el P-valor (no ajustado) hace una escalera

-Transcription y epi: Hacer la regresion lineal para el ZSCAN5 en base a las cg significativas de CYP3A5

Transcription y metabolizador: Modelo simple sobre los 660 individuos de transcriptomica

1. Transcriptomica: filtrar las gene counts para los 660 individuos de genostar (CYP_gene_counts_normalizadas_nombres_transcriptomica_660_individuos)

Se parte de gene_counts_722_individuos_normalizados y se filtra para los 660 individuos de genostar y para los CYPs

2. Tipo metabolizador: filtrar y formatear los datos de input

Se parte del excel salida_genostar_filtrado_transcriptomica y se filtra para solo tener la info del matbolizer status y de la misma forma, se guarda en CYP_metabolizador_nombres_genostar_660_individuos

3. Fusion: Aplicar modelos

Con script_modelos_metabolizador_transcriptomica, se hace un modelo lineal sin basarse en limma y no hay correlación en ninguno de los casos

No sale nada significativo

-CYP2D6: 0.6132

-CYP2B6: 0.3147

-CYP3A5: 0.2816

-CYP2C9: 0.5997

-CYP2C19: 0.8067

Transcription y epi CYP3A5: analizar posible DMR

Analizando las posiciones de las 5 CpGs signifivativas se observa que cg02084114, cg12694063 y cg13596235 estan muy juntas y pueden ser una DMR y hay que comprobarlo

1. Obetener los p-valores (no ajustados) de las CpGs de CYP3A5

Se sacan con el script script_modelos_epi_transcriptomica y se guardan en DMR_CYP3A5

2. Obtener las posicion de las CpGs

En en el excel DMR_CYP3A5 se hace BUSCARV a la hoja CYP3A5 del excel

CpGs_por_CYP_ventana100kb_con_betas para obetener las posiciones

3. Se analiza si las CpGs cercanas hacen una escalera en sus p-valores (Ballon plot)

En el excel DMR_CYP3A5 se ordena por posicion y se busca la zona con las CpGs (se marcan en rojo) y hace un ballon plot con la herramienta

Link: http://www.bioinformatics.com.cn/plot_basic_ballon_plot_048_en

- Usuario: encuestadesatisfaccioncbmso@gmail.com
- Contraseña: 123456

Transcripcion y epi: modelo simple: $Mvalues \sim gene_counts$ (para ZSCAN5)

Se sigue el procedimiento del dia 25/05/26

1. Transcriptomica: gene counts del gen ZSCAN25

1. gene_counts_722_individuos_normalizados
2. ZSCAN25_gene_counts_normalizadas_nombres_transcriptomica_722_individuos
3. ZSCAN25_gene_counts_normalizadas_nombres_transcriptomica_238_individuos
4. ZSCAN25_gene_counts_normalizadas_nombres_epi_238_individuos (TRANSCRIPTOMICA)

2. Epi: 104 CpGs del CYP3A5

CpGs_por_CYP_ventana100kb_con_Mvalues.xlsx lo uncioque se va a usar solo la hoja de CYP3A5

3.Fusion: Aplicar modelos

Script modelos_epi_transcriptomica al final en apartado ZSCAN25 y se saca el excel DMPs_ZSCAN25_MS

4. Evaluar si las DMPs de ZSACN25 estan en la zona DMRs de CYP3A5

En el excel DMPs_ZSCAN25_MS se hace BUSCARV a la hoja Zona DMR del excel DMRs_CYP3A5

Resultados

- Transcripcion y metabolizador: No sale nada significativo para regresion transcriptomica y tipo de metabolizador para los 660 individuos de transcriptomica, tiene sentido porque el tipo de metabolizador no depende de la expresion del gen sino de la svariantes que tiene y esas son invariables, solo afectaria si tiene alguna variante framshift o de stop, que hace que no se produzca la enzima
- DMR en CYP3A5 en el ballon plot
- DMPs en ZSCAN25: queda por analizar

03/06/26

-Poster CBM

05/06/26

Objetivo

- Ballon plot DRM en DMR_CYP3A5 (credenciales en el correo)
- Analizar DMPs en ZSCAN25 y su relacion con las de CYP3A5

-Ver correo process CYP2D6, pero creo que el bajo call rate va a venir de que no tenemos rs que definen alelos segun proces_cyp2d6 y sobretodo se pierden muchos *1

Transcripcion y epi CYP3A5: analizar posible DMR

Analizando las posiciones de las 5 CpGs significativas se observa que cg02084114, cg12694063 y cg13596235 estan muy juntas y pueden ser una DMR y hay que comprobarlo

3. Se analiza si las CpGs cercanas hacen una escalera en sus p-valores (Ballon plot)

En el excel DMR_CYP3A5 se ordena por posicion y se busca la zona con las CpGs (se marcan en rojo) y hace un ballon plot con la herramienta

Link: http://www.bioinformatics.com.cn/plot_basic_ballon_plot_048_en

- Usuario: encuestadesatisfaccioncbmso@gmail.com
- Contraseña: 123456

Los p-valores transforman a $-\log_{10}$ para que el cambio sea proporcional (¿Por qué usamos el signo negativo en $-\log_{10}(\text{p-value})$?

Porque queremos que los p-valores más pequeños (más significativos) se conviertan en números más grandes.

Si NO pusiéramos el signo negativo: Un p-valor pequeño (0.0001) daría un número negativo grande (-4). Un p-valor grande (0.8) daría un número casi cero (-0.09).

Eso es lo contrario de lo que queremos en un gráfico donde el tamaño del globo representa significancia.)

Se guarda en Ballon_plot_DMR_CYP3A5

Transcripcion y epi: modelo simple: Mvalues ~ gene_counts (para ZSCAN5)

4. Evaluar si las DMPs de ZSACN25 estan en la zona DMRs de CYP3A5

En el excel DMPs_ZSCAN25_MS se hace BUSCARV a la hoja Zona DMR del excel DMRs_CYP3A5 y se hace hoja filtrada para FDR (quedan 29 cg) y para Bonferroni (quedan 13 cg). Sobre la hoja filtrada por Bonferroni se añade una columna con el p-valor de esas cg (BUSCARV a hoja DMR del excel DMRs_CYP3A5)

Resultado: De las cinco significativas de CYP3A5, cuatro estan en el supuesto DMR y la otra cg05008948 no esta en DMR pero es significativo. Se analizan las CpGs de CYP3A5 para el gen ZSACN25 y salen 13 significativas, de las cuales tres eran de las cinco significativas de CYP3A5 (la suleta cg05008948 y dos del DMR cg02084114 y cg04706801), las 10 restantes no son significativas en CYP3A5 pero si para ZSACN25 y de esas diez, seis estan en el supuesto DMR de CYP3A5 y las otras cuatro no estan en el DMR de CYP3A5

Transcripcion y epi: otros modelos para para ZSCAN5

1. Transcriptomica: gene counts del gen ZSCAN25

ZSCAN25_gene_counts_normalizadas_nombres_epi_238_individuos (TRANSCRIPTOMICA)

2. Epi: 104 CpGs del CYP3A5

3.Fusion: Aplicar modelos para ZSCAN25

Script modelos_epi_transcriptomica al final en apartado ZSCAN25 y se saca el excel DMPs_ZSCAN25

-MS: Mvalues ~ gene_counts: (13 cg) En DMPs_ZSCAN25_MS hoja filtrada por Bonferroni

-M1: Mvalues ~ gene_counts + age + sex:

-M6: Mvalues ~ gene_counts + age + sex + smoking + Ctrl_1 + Ctrl_2: (14cg)

-M8: Mvalues ~ gene_counts + age + sex + smoking + Ctrl_1 + Ctrl_2 + anc_1 + anc_2: (14cg)

-MC: Mvalues ~ gene_counts + age + sex + smoking + caso/control + cell_1 + cell_2 + Ctrl_1 + Ctrl_2 + anc_1 + anc_2: 0cg

Nos quedamos con el M8 porque así se ha decidido antes

4. Evaluar si las DMPs de ZSCAN25 están en la zona DMRs de CYP3A5

En el excel DMPs_ZSCAN25_M8 se hace BUSCARV a la hoja Zona DMR del excel DMRs_CYP3A5 y se hace hoja filtrada para Bonferroni (quedan 14 cg). Sobre la hoja filtrada por Bonferroni se añade una columna con el p-valor de esas cg (BUSCARV a hoja DMR del excel DMRs_CYP3A5)

Resultado: De las cinco significativas de CYP3A5, cuatro están en el supuesto DMR y la otra cg05008948 no está en DMR pero es significativa. Se analizan las CpGs de CYP3A5 para el gen ZSCAN25 y salen 14 significativas, de las cuales tres eran de las cinco significativas de CYP3A5 (la suleta cg05008948 y dos del DMR cg02084114 y cg04706801), las 11 restantes no son significativas en CYP3A5 pero sí para ZSCAN25 y de esas once, seis están en el supuesto DMR de CYP3A5 y las otras cinco no están en el DMR de CYP3A5

Genostar bajo call rate CYP2D6

Resultados

-DMR en CYP3A5 en Ballon_plot_DMR_CYP3A5

-DMPs en ZSCAN25: con el modelo simple hay 13 cgs que coinciden bastante con la supuesta DMR y con el M8 hay 14cgs que coinciden bastante con la supuesta DMR, por lo que se llega a la conclusión de que esa zona tiene una tendencia y puede ser una posible DMR